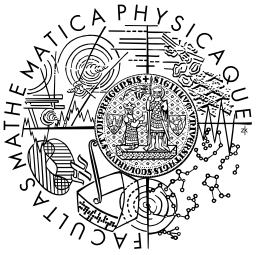

MATEMATICKO-FYZIKÁLNÍ FAKULTA
Univerzita Karlova

BAKALÁŘSKÁ PRÁCE

Marek Bečvář

Evoluce robotů v simulovaném fyzikálním prostředí

Katedra softwaru a výuky informatiky

Vedoucí bakalářské práce: RNDr. František Mráz, CSc.

Studijní program: Informatika

Studijní obor: Informatika se specializací Umělá inteligence

Praha 2023

Prohlašuji, že jsem tuto bakalářskou práci vypracoval(a) samostatně a výhradně s použitím citovaných pramenů, literatury a dalších odborných zdrojů. Tato práce nebyla využita k získání jiného nebo stejného titulu.

Beru na vědomí, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., autorského zákona v platném znění, zejména skutečnost, že Univerzita Karlova má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle §60 odst. 1 autorského zákona.

V ..... dne ....

Podpis autora

Poděkování.

Název práce: Evoluce robotů v simulovaném fyzikálním prostředí

Autor: Marek Bečvář

Katedra: Katedra softwaru a výuky informatiky

Vedoucí bakalářské práce: RNDr. František Mráz, CSc., Katedra softwaru a výuky informatiky

Abstrakt: Abstrakt.

Klíčová slova: klíčová slova

Title: Evolution of robots in a simulated physical environment

Author: Marek Bečvář

Department: Department of software and computer science education

Supervisor: RNDr. František Mráz, CSc., Department of software and computer science education

Abstract: Abstract.

Keywords: key words

Obsah

Úvod

Následuje několik ukázkových kapitol, které doporučují, jak by se měla bakalářská práce sázet. Primárně popisují použití TEXové šablony, ale obecné rady poslouží dobře i uživatelům jiných systémů.

1. Základní pojmy

V této kapitole vysvětlíme a rozebereme důležité pojmy, se kterými se v dalším popisu práce budeme setkávat. Znalost těchto pojmů je potřebná pro pochopení důvodů volby daných vybraných technologií a pro pochopení základního rozboru implementace řešení, kterou popíšeme v následujících kapitolách.

V této kapitole nejdříve vysvětlíme základní teorii evolučních algoritmů (oddíl 1.1) a dále si v oddíle 1.1.1 ukážeme již existující knihovny pracující nebo umožňující pracovat s genetickými algoritmy. Poté se v oddílu 1.2 podíváme na základ teorie umělých neuronových sítí a v oddílu 1.3 popíšeme neuroevoluci, kategorii pokročilých evolučních algoritmů sloužící přímo k vývoji umělých neuronových sítí (algoritmy NEAT v oddílu 1.3.1 a HyperNEAT v oddílu 1.3.2). Dále popíšeme simulátory prostředí (oddíl 1.4) a fyzikální simulátory (oddíl 1.4.2), které využijeme pro simulaci při vyvíjení našich robotů.

1.1 Evoluční algoritmy

Evoluční algoritmus je označení pro stochastické vyhledávací algoritmy, které svými procesy napodobují principy Darwinovy evoluční teorie o přirozeném výběru a přežívání nejlepších jedinců. Pomocí těchto algoritmů se často snažíme optimalizovat nějaké procesy, nebo vlastnosti systémů, a tedy evoluční algoritmy můžeme označovat i jako optimalizační algoritmy. Mohou být úspěšné v řešení komplexních problémů (např. aproximace NP-úplných problémů) a problémů se složitě definovanou hodnotící funkcí. Stochastická vlastnost těchto algoritmů způsobuje, že algoritmy nezaručují nalezení optimálního řešení, ale jsou schopné se tomuto řešení přiblížit nějakým kvalitním suboptimálním řešením.

Mezi známé varianty evoluční algoritmů patří:

- *Genetické algoritmy (GA)* – kódující řešení pomocí vektorů binárních hodnot,
- *Evoluční strategie (ES)* – pro reprezentaci řešení, na rozdíl od GA, využívají ES reálné hodnoty a vektory reálných hodnot,
- *Genetické programování (GP)* – reprezentuje řešení skládáním složitějších operací (např. pravidel bezkontextových gramatik, stromů s funkcemi a konstantami).

Jednotlivá řešení v evolučních algoritmech jsou nazývána jako **jedinci** s vlastními genetickými informacemi (**genotyp**). Kvalitu genotypu (označujeme jako **fitness**) je možné pro daný problém otestovat, vyhodnocením předem definované *hodnotící funkce*. Fitness je potom číselná hodnota, kterou se v procesem evolučního algoritmu snažíme maximalizovat/minimalizovat (dle definice hodnotící funkce). Množinu takových jedinců v evolučních algoritmech nazýváme **populace**. Celý vývoj evolučního algoritmu potom probíhá v cyklech, kdy v každé iteraci je otestována kvalita genotypu celé populace. Tyto jednotlivé iterace nazýváme **generace**.

Vedle inicializace populace, která je obvykle provedena náhodně, jsou důležitými částmi evolučních algoritmů tzv. **genetické operátory**. Jedná se o procesy

silně inspirované přírodními jevy pozorovaných při evoluci organismů. Tak jako se vyvíjí organismy v přírodě, za účelem udržení těch nejvhodnějších vlastností pro dané prostředí, vyvíjí se i jedinci v evolučních algoritmech, aby se přibližovali optimálnímu řešení zadaného problému (optimalizovali hodnotící funkci). Proces vývoje v evolučních algoritmech je pak zajištěn třemi genetickými operátory – **selekce**, **křížení** a **mutace**. Všechny budou blíže popsány v následujících odstavcích. Určité varianty evolučních algoritmů nemusí využívat všechny genetické operátory.

Selekce Selekce je proces, který vybírá jedince z populace, kteří buď přímo postoupí do další generace, nebo budou vybráni jako rodiče (zdroj genetických informací) pro další generaci. Selekce má upřednostňovat jedince s vyšší kvalitou genotypu, což by mělo v průběhu vývoje produkovat kvalitnější jedince, a tedy směřovat vývoj k optimálnímu řešení. Při vývoji může být aplikována ve dvou bodech. Pomocí selekce můžeme vybírat rodičovské jedince, kteří budou použiti pro tvorbu potomků, ze kterých se následně stane nová populace pro další generaci (*mating selection=selekce pro křížení*). Zároveň můžeme selekci využít pro sestavení nové generace výběrem z nejlepších jedinců původní populace a nově vytvořených potomků (*environmentální selekce*).

Nejpoužívanějšími způsoby implementace operátoru selekce jsou *turnajová selekce* a *ruletová selekce*.

Při *turnajové selekci* náhodně vybereme určitý počet jedinců z populace a dle jejich ohodnocení (fitness) je rozřadíme (uspořádáme turnaj mezi jedinci). V tuto chvíli nejčastěji selekce vybere vítěze turnaje (nejlepšího jedince z turnaje). Existují i pravděpodobnostní varianty *turnajové selekce*, kdy pořadí v turnaji určuje pravděpodobnost zvolení daného jedince (vítěz turnaje má nejvyšší pravděpodobnost zvolení, další v pořadí mají klesající šanci na zvolení). Výhodou *turnajové selekce* je, že nedává žádná omezení na fitness jedinců. Stačí nám, když jdou jednotlivé hodnoty fitness porovnat a rozlišit tak, která je lepší a která horší.

Ruletová selekce je abstrakce ruletového kola, kde každý jedinec má šanci na zvolení (šance, že jeho hodnota padne na ruletovém kole) přímo úměrnou jeho fitness. Tato selekce se potom provádí opakovaně, dokud nevybereme požadovaný počet jedinců, nad celou populací a ne pouze nad náhodně vybranou podmnožinou jedinců z populace (jak tomu bylo u *turnajové selekce*). Pokud se v populaci nachází jedinec s dominantní hodnotou fitness, která výrazně překonává ostatní jedince v populaci, může se stávat, že bude docházet k opakovanému výběru jednoho a toho samého jedince, což může vést k velmi rychlému zúžení prohledávaného prostoru a tedy nalezení neoptimálního řešení (vývoj může uvíznout v tzv. *lokálním optimu*).

Křížení Křížení je proces, při kterém nějakým stylem kombinujeme genetické informace dvou (nebo více) jedinců. Tímto procesem vznikají potomci původních jedinců, kteří se mohou stát novou populací v následující generaci. Výběr jedinců pro křížení zajišťuje **selekce**. Křížení umožňuje důkladnější prohledávání prostoru možných řešení mezi již prohledanými možnostmi. Existuje mnoho variant křížení. Často využívanými variantami křížení jsou např. *jednobodové křížení*, *vícebodové křížení* nebo *uniformní křížení*.

Při *jednobodovém křížení* (pro dva rodičovské jedince) vybereme náhodně

jedno místo (bod dělení), ve kterém oba genotypy rozdělíme. Genetickou informaci potomků následně vytvoříme tak, že složíme zpět rozdělené části genotypů různých rodičů (např. první potomek vznikne složením první části genotypu prvního rodiče a druhé části genotypu druhého rodiče a druhý potomek naopak). *Vícebodové křížení* probíhá stejně, pouze na začátku volíme vícero bodů, ve kterých genotypy rozdělíme a tak máme více možností, jak genotyp složit zpět.

Uniformní křížení při tvorbě potomků najednou prochází celý genotyp všech rodičů a u každé hodnoty uniformně náhodně vybere, z jakého rodiče se daný kus genetické informace zkopíruje do potomka. U tohoto typu křížení lze jednoduše použít i víc než dva rodiče pro tvorbu potomků.

Jedná se o příklady metod křížení, často používané pro **genetické algoritmy**. Algoritmy pracující s reálnými hodnotami nebo jinak složitými strukturami mohou využívat jiné metody, pracující specificky s danými hodnotami genotypu (příkladem může být *křížení průměrováním* reálných hodnot dvou nebo více rodičů).

Mutace Při mutaci náhodně měníme malé části genotypu jedinců. Obvykle probíhá po vygenerování nových potomků pomocí **křížení**. Pomocí mutace evoluční algoritmy rozšiřují prostor prohledávaných řešení. Správně zvolená hodnota mutace zabraňuje uvíznutí evolučního algoritmu v lokálních optimech. Příliš silná mutace ale může způsobovat velké změny v genotypech a tedy tak zabránit vývoji jakýchkoli vlastností jedinců, které by vedli k optimalizaci řešení. Hodnotou mutace označujeme pravděpodobnost, že část genotypu bude pozměněna.

Styl, jakým se genotyp mutuje, je závislý na typu evolučního algoritmu. Pro genetické algoritmy s genotypem tvořeným vektorem binárních hodnot se může jednat o např. náhodný *bit flip* (tedy změnu dané hodnoty z 0 na 1 nebo naopak). U jiných typů evolučních algoritmů je možné používat např. přiřazení nové náhodně vygenerované hodnoty z rozsahu povolených hodnot pro danou část genotypu, nebo posun o malou náhodně vygenerovanou hodnotu.

Elitismus Jelikož je evoluční vývoj proces postavený na náhodě, mohlo by se stát, že náhodnou mutací přijdeme o nějaké potřebné vlastnosti z nejlepších jedinců a těch už nikdy nebudeme moci dosáhnout. Elitismus umožní tyto aktuálně nejlepší vlastnosti mezi generacemi zachovat. Jedná se o speciální proces, řadící se většinou k **selekci**, který umožňuje zachovat určité množství jedinců mezi generacemi beze změny. Obvykle jeden nebo malé množství nejlepších jedinců je po každé generaci přesunuto beze změny do další (tedy neprojdou žádnou mutací a jejich genotyp je stejný mezi generacemi).

Následující ukázka pseudokódu předvede jednoduchý příklad běhu evolučního algoritmu.

```
POP = náhodná inicializace populace
otestuj populaci a vypočti fitness
dokud problém není vyřešen:
    PARENTS = pomocí selekce vyber množinu rodičů
    OFFSPRING = křížením (z PARENTS) vytvoř množinu potomků
    MUT_OFFSPRING = aplikuj mutaci na potomky z OFFSPRING

    POP = z potomků v MUT_OFFSPRING vytvoř populaci další generace
    otestuj novou populaci POP a vypočti fitness
```

V ukázce můžeme vidět jednotlivé kroky jednoduchého evolučního algoritmu. Nejdříve inicializujeme populaci a zjistíme fitness jedinců. Následně dokud se nesplní podmínka pro ukončení evolučního vývoje (např. dosažení specifické fitness hodnoty), bude cyklicky v generacích probíhat vývoj populace, dokud se neobjeví takový jedinec, který zadaný problém vyřeší.

Možnosti paralelizace Všechny části evolučních algoritmů jsou ve své podstatě velmi jednoduché a tedy i rychlé na výpočet. Jediný bod, který může vývoj zpomalit je samotné testování jedinců. Například, když jedinec reprezentuje robota, tak jeho hodnocení vyžaduje simulaci robota po určitou dobu. Jelikož každý robot musí být simulován zvlášť, je tento krok v našem evolučním algoritmu zdaleka ten nejnáročnější co se týče doby výpočtu. Naštěstí ve většině příkladů použití evolučních algoritmů, je tento krok možné poměrně jednoduše paralelizovat a i v našem případě tomu tak je. Jednotliví jedinci jsou v absolutní většině evolučních algoritmů naprosto nezávislí na ostatních. Pokud to simulační prostředí dovolí, je možné nechat každého robota simulovat nezávisle na ostatních ve vlastním vlákně (procesu) a tak využít moderních vícevláknových procesorů. Tato změna je poměrně jednoduchá na implementaci a absolutní většina evolučních algoritmů může tohoto využít pro mnohonásobné urychlení celého procesu evolučního vývoje.

1.1.1 Existující implementace

Pro vývoj řízení robotů budeme využívat evoluční algoritmy. Naše knihovna tedy bude implementovat několik alespoň základních genetických operátorů, používaných při vývoji jedinců a co nejjednodušeji umožňovat jejich konfiguraci před spouštěním jednotlivých experimentů. Naším cílem je co možná nejvíce zpřístupnit knihovnu, která má být výsledkem této práce, aby uživatel se základní znalostí genetických algoritmů a programovacího jazyka byl schopný pochopit běh algoritmu a v případě potřeby mohl jednoduše provádět zásahy do jeho běhu. Není tedy naším cílem najít tu nejefektivnější knihovnu, nýbrž tu, která přinese výhody jako přehlednost a snadnou úpravu algoritmů, bez větších obtíží s implementací a pochopením knihovny.

Dále představíme několik knihoven implementujících nebo usnadňujících implementaci genetických algoritmů nebo jejich částí. Celkem se podíváme na dvě knihovny – DEAP (sekce 1.1.1.1) a Inspyred (sekce 1.1.1.2). Existují další podobné knihovny (Pyevolve, PyGAD), které ale oproti DEAP a Inspyred nepřináší mnoho dalších užitečných možností.

1.1.1.1 DEAP

DEAP (*Distributed Evolutionary Algorithms in Python*) (DEAP) je open-source Python knihovna pro rychlou tvorbu a prototypování evolučních algoritmů. Snaží se tvorbu evolučních algoritmů zjednodušit pomocí přímočarého postupu, podobného pseudokódu, který je se základní znalostí knihovny poměrně jednoduchý na porozumění.

Knihovna je tvořena ze dvou hlavních struktur `creator`, který slouží k vytváření genetických informací jedinců z libovolných datových struktur a `toolbox`, který je seznamem nástrojů (genetických operátorů), které mohou být použité při sestavování evolučního algoritmu. Dalšími menšími strukturami jsou `algorithms` obsahující 4 základní typy algoritmů a `tools` implementující další základní operátory (části operátorů), které je posléze možné přidávat do `toolbox`. Pomocí těchto základních stavebních bloků mohou uživatelé poměrně jednoduše začít tvořit skoro libovolné evoluční algoritmy (Fortin a kol., 2012).

Následuje ukázka kódu tvorby základních částí evolučního algoritmu pro *One Max* problém, popsaná v oficiální dokumentaci knihovny DEAP. V *One Max* problému máme populaci jedinců, kteří reprezentují vektor binárních čísel předem zvolené délky. Cílem je potom vyvinout takového jedince, který má na všech pozicích vektoru nastavené jedničky.

Nejprve v kódu importujeme potřebné části knihovny. Dále využijeme `creator` pro tvorbu specifických tříd, které budeme potřebovat pro popis jedinců v našem evolučním algoritmu.

`Creator` `Creator` je třída sloužící jako *factory* pro uživatelem definované třídy. Tedy s její pomocí můžeme vytvářet nové třídy za běhu programu. To se hodí, protože různé problémy mohou vyžadovat velmi rozdílné typy jedinců. Tvorba třídy probíhá pomocí funkce `create`, která jako argumenty přijímá jméno vytvářené třídy, dále třídu, od které nová třída bude dědit a poté může následovat řada argumentů, které mohou být využity jako další argumenty naší nové třídy.

```
creator.create("FitnessMax", base.Fitness, weights=(1.0,))
creator.create("Individual", list, fitness=creator.FitnessMax)
```

První řádek popisuje tvorbu třídy `FitnessMax`, dědící od třídy `Fitness` knihovny DEAP a zároveň obsahuje argument `weights`, který specifikuje, že fitness bude maximalizovat jediný cíl (pomocí DEAP můžeme specifikovat hned několik cílů najednou, ve kterých chceme, aby se jedinci zlepšovali, přičemž jednotlivým cílům můžeme přiřadit různé váhy).

Na druhém řádku vytváříme třídu jedince `Individual`, která dědí od třídy `list` a bude obsahovat parametr `fitness`, do nějž přiřadíme vytvořenou třídu `FitnessMax`.

`Toolbox` Dále využijeme vlastní třídy pro tvorbu specifických typů, reprezentujících jedince a celou populaci. `Toolbox` se stane úložištěm pro všechny objekty, které budeme při tvorbě evolučního algoritmu používat. Do tohoto úložiště můžeme objekty přidávat funkcí `register` a můžeme je odebrat funkcí `unregister`.

```
# založení úložiště
toolbox = base.Toolbox()

# generátor atributů pro jedince
toolbox.register("attr_bool", random.randint, 0, 1)

# inicializace struktur jedince a populace
toolbox.register("individual",
                 tools.initRepeat,
                 creator.Individual,
                 toolbox.attr_bool,
                 100)
toolbox.register("population",
                 tools.initRepeat,
                 list,
                 toolbox.individual)
```

Nejdříve jsme vytvořili `toolbox` jako úložiště pro naše funkce. Dále jsme přidali generátor `toolbox.attr_bool()`, tvořený z funkce `random.randint()`, který když zavoláme, náhodně vygeneruje celé číslo mezi 0 a 1.

Dále jsme přidali dvě inicializační funkce `toolbox.individual()` pro inicializaci jedinců a `toolbox.population()` pro inicializaci celé populace.

Pro vytvoření jedince používáme funkci `tools.initRepeat()`, která jako první argument přijímá kontejner (v našem případě třídu jedince, kterou jsme definovali dříve jako potomka třídy `list`). Ten bude při inicializaci naplněn funkcí `toolbox.attr_bool()` zavolanou 100 krát, jak specifikují následující dva argumenty. Při inicializaci celé populace budeme postupovat stejně, jen jsme ještě v tento moment nespecifikovali, kolik jedinců bude do populace vytvořeno.

Hodnotící funkce Hodnotící funkce je pro tento problém jednoduchá. Potřebujeme pouze spočítat, kolik jedniček obsahuje daný jedinec (vektor binárních čísel).

```
def evalOneMax(individual):
    return sum(individual)
```

Genetické operátory Knihovna umožňuje dva přístupy, jak můžeme využívat genetické operátory. Buď je můžeme volat přímo z `tools`, nebo je nejdříve registrujeme do úložiště `toolbox` a z něho je budeme používat. Registrace je považována za vhodnější variantu, protože to do budoucna zjednodušuje změny používaných operátorů.

```
toolbox.register("evaluate", evalOneMax)
toolbox.register("mate", tools.cxTwoPoint)
toolbox.register("mutate", tools.mutFlipBit, indpb=0.05)
toolbox.register("select", tools.selTournament, tournsize=3)
```

Hodnotící funkci realizuje funkce `toolbox.evaluate()`, tvořící alias na dříve vytvořenou hodnotící funkci. Funkce `toolbox.mate()` je v tomto příkladu alias za `tools.cxTwoPoint()`, což je v knihovně implementovaná funkce provádějící dvoubodové křížení. Podobně tvoříme i funkce pro mutaci jedinců (v tomto případě binární mutaci – `tools.mutFlipBit`), kde argument `indpb` určuje pravděpodobnost mutace jednotlivých parametrů jedince a v poslední řadě funkci pro selekci (turnajová selekce s turnajem mezi třemi jedinci).

Evoluce Když jsou všechny části připravené, vlastní evoluční algoritmus se sestaví kombinací jednotlivých definovaných částí, aplikováním registrovaných funkcí na populaci nebo jedince dle potřeby.

Na inicializované populaci se provádí evoluce, dokud nějaký z jedinců nesplní zadaný úkol, nebo dokud evoluce nedosáhne určitého počtu generací.

Pro stručnější popis zbytek kódu vynecháme, protože jsme si již předvedli všechny části spojené s definováním evolučního algoritmu, které jsou specifické pro práci s knihovnou DEAP. Úplnou ukázku lze najít v oficiální dokumentaci knihovny (DEAP).

Podle článku (Fortin a kol., 2012), který porovnává několik Python modulů pro usnadnění práce s evolučními algoritmy, je DEAP nejefektivnější, tedy tvoří nejkratší kód, podle počtu řádků potřebných pro implementaci algoritmu řešícího *One Max* problém z ukázky.

1.1.1.2 Inspyred

Inspyred (Garrett, 2012) poskytuje většinu z nejpoužívanějších evolučních algoritmů a dalších přírodou inspirovaných algoritmů (simulace reálných biologických systémů – např. optimalizace mravenčí kolonií) v jazyce Python.

Knihovna přichází s funkční implementací řady základních evolučních algoritmů ve formě komponentů (Python funkcí), které si uživatel může sám upravovat, rozšiřovat, nebo je úplně nahradit vlastními funkcemi. Při tvorbě algoritmu pak uživatel skládá dohromady několik komponentů, které ovlivňují, jak celý vývoj bude probíhat. Těmito komponenty jsou:

a) komponenty specifické danému problému:

- `generator` – určuje jak se generují řešení (jedinci),
- `evaluator` – definuje jak se vypočítává fitness jedinců,

b) komponenty specifické danému danému evolučnímu algoritmu:

- `observer` – definuje jak uživatel sleduje evoluci,
- `terminator` – rozhoduje, kdy by měla evoluce skončit,
- `selector` – rozhoduje, kteří jedinci by se měli stát rodiči další generace,
- `variator` – definuje jak jsou potomci vytvořeni z rodičovských jedinců,
- `replacer` – volí, kteří jedinci mají přežít do další generace,
- `migrator` – určuje jak se přenáší jedinci mezi různými populacemi/generacemi,

- `archiver` – definuje jak jsou jedinci ukládání mimo stávající populaci.

Libovolná z těchto komponent pak může být nahrazena odpovídající vlastní implementací (Tonda, 2020).

Následuje jednoduchý příklad z dokumentace knihovny Inspyred, který nám rychle představí možnou práci s knihovnou. Budeme řešit problém srovnatelný s problémem *One Max* představeným u příkladu knihovny DEAP. Nyní je cílem, aby hodnota vektoru interpretována jako binární zápis celého čísla byla co nejvyšší (opět chceme, aby výsledný jedinec měl na všech místech vektoru nastavené jedničky).

Na začátku se importuje knihovna Inspyred a modul `random`.

`Generator` Pro řešení problému vytvoříme vlastní generátor jedinců populace. Všechny generátory knihovny Inspyred mají vždy stejné dva argumenty:

- `random` – objekt pro generování náhodných čísel,
- `args` – slovník dalších argumentů, které můžeme libovolně přidat.

```
def generate_binary(random, args):
    bits = args.get('num_bits', 8)
    return [random.choice([0, 1]) for i in range(bits)]
```

Zde vytváříme vlastní funkci `generate_binary`, která bude sloužit jako generátor jedinců. V této funkci nejdříve do proměnné `bits` načteme hodnotu z argumentu `num_bits` (s jeho definicí se setkáme později) a poté vytvoříme jedince jako seznam, který naplníme náhodně zvolenými binárními hodnotami.

`Evaluator` Podobně jako generátor, tak i pro vyhodnocení fitness jedinců vytvoříme vlastní funkci. Funkce tohoto typu opět vyžadují dva argumenty:

- `candidate` – jedinec, kterého ve funkci vyhodnocujeme, a
- `args` – slovník dalších argumentů, které můžeme libovolně přidat.

V knihovně se často setkáme s dekorátory funkcí. Přesněji funkce, které tvoříme pro `evaluator` vyžadují dekorátor `@evaluator`. Dekorátory se používají, protože vytváříme funkce, které budou použité v rámci jiných interních funkcí (např. naše vlastní vyhodnocovací funkce pracuje pouze s jedním jedincem, ale funkce se bude při vyhodnocení fitness interně používat pro celou populaci).

```
@inspyred.ec.evaluators.evaluator
def evaluate_binary(candidate, args):
    return int("".join([str(c) for c in candidate]), 2)
```

Vyhodnocení jedince tedy vezme všechny prvky jeho vektoru, přečte je a vyhodnotí výstup jako binární zápis nějakého celého čísla. Toto číslo je potom výstupní ohodnocení pro daného jedince.

Genetický algoritmu Vytvořili jsme všechny potřebné části, specifické pro tento problém a tedy je můžeme použít pro vytvoření výsledného genetického algoritmu. Knihovna Inspyred nabízí několik různých typů evolučních algoritmů (genetické algoritmy, evoluční strategie, simulované žíhání a další). Pro tento problém vybereme základní formu genetického algoritmu, který je nám v této knihovně dostupný.

```
rand = random.Random()
ga = inspyred.ec.GA(rand)
ga.observer = inspyred.ec.observers.stats_observer
ga.terminator = inspyred.ec.terminators.evaluation_termination
```

Zde nejprve vytváříme objekt pro generování náhodných čísel, který bude využíván v algoritmu. Na druhém řádku pak vytváříme objekt samotného genetického algoritmu. Jak jsme zmínili výše, všechny algoritmy mají určité komponenty, které uživatel může měnit za jiné, nebo je celé sám upravovat. Pro ukázku zde měníme komponenty `observer` a `terminator`. Pro `observer` volíme připravený `stats_observer`, což je funkce, která v průběhu algoritmu bude vypisovat statistiky z běhu evoluce. Výstup tohoto `observeru` bude mít následující podobu:

```
Generation Evaluation   Worst    Best   Median   Average     Std Dev
---------- ---------- ------- ------- -------- --------- -----------
         0        100       6    1016    564.5    536.02  309.833954

Generation Evaluation   Worst    Best   Median   Average     Std Dev
---------- ---------- ------- ------- -------- --------- -----------
         1        200      29    1021    722.5    675.22  247.645576
```

Zároveň měníme i `terminator` za funkci `evaluation_termination`, která jednoduše zahlásí, že evoluce má skončit, pokud evoluce dosáhla maximálního počtu vyhodnocení.

Evoluce Samotné spuštění a vyhodnocení evoluce je pak velmi jednoduché.

```
final_pop = ga.evolve(evaluator=evaluate_binary,
                      generator=generate_binary,
                      max_evaluations=1000,
                      num_elites=1,
                      pop_size=100,
                      num_bits=10)

final_pop.sort(reverse=True)
```

Genetický algoritmus se lehce spustí pomocí funkce `evolve`, které předáme požadované parametry jako náš zvolený `evaluator` a `generator`, dále pro `terminator` vkládáme maximální počet vyhodnocení, které chceme při vývoji dovolit. Dále je možné pro tyto algoritmy specifikovat jevy jako třeba elitismus. V poslední řadě `pop_size` určuje velikost populace, se kterou bude evoluce pracovat a vkládáme zde dříve zmíněný argument `num_bits`, určující velikost vektoru jedince.

Další informace o příkladu a jednotlivých funkcích lze nalézt v oficiální dokumentaci Inspyred (Garrett, 2012).

1.1.1.3 Porovnání

Při srovnání těchto knihoven jsme převážně sledovali jak intuitivní práce s nimi je. Cílem této práce je vytvořit co možná nejvíce otevřenou platformu, se kterou bude moci uživatel provádět experimenty při vývoji řízení robotů. Uživatel se základní znalostí evolučních algoritmů by tak měl být schopný jednoduše pochopit všechny části knihovny a pokud by měl potřebu, sám si doplnit nějaké specifické části.

Z vlastního pohledu, ačkoli knihovna DEAP umožňuje tvorbu asi libovolného evolučního algoritmu velmi kompaktním způsobem, potřeba pochopit a seznámit se s procesem tvorby vlastních tříd a objektů, na kterém je DEAP postavený, je poměrně velkou překážkou pro možného nového uživatele naší knihovny, který by si mohl chtít upravit proces evolučních algoritmů dle svých požadavků. Ačkoli méně kompaktní, řešení knihovny Inspyred 1.1.1.2, které dělí algoritmy do základních stavebních bloků, kde každá část může být se základní znalostí Pythonu pozměněna, se mi pro náš účel zamlouvá více. Inspyred ale zároveň implementuje řadu dalších algoritmů, které by v našem případě vůbec nemusely být využitelné a pouze by mohly zvyšovat minimální množství znalostí potřebných k práci s naší knihovnou.

Na základě vyzkoušených a předvedených knihoven, které se dle různých zdrojů (Fortin a kol., 2012) zdály jako nejvhodnější pro naše využití, jsme se rozhodli inspirovat se knihovnou Inspyred (stylem, jakým knihovna dělí algoritmus na základní stavební bloky) a vytvořit vlastní implementaci většiny základních stavebních bloků, které bude možné použít při tvorbě vlastních evolučních algoritmů v naší knihovně. Tyto bloky budou co možná nejvíce obecné a snadno konfigurovatelné funkce s předepsaným výstupním typem, aby uživatel mohl snadněji porozumět implementaci každého z bloků a zároveň aby měl možnost vytvářet vlastní bloky (Python funkce) a ty jednoduše zapojit do evolučního algoritmu. Právě tak jak tomu je v knihovně Inspyred.

Celý projekt je směřován zároveň jako možný studijní materiál, a tak navíc věřím, že pro studenty bude možnost vidět v kódu funkční implementaci jednotlivých částí algoritmů tak, jak běží na pozadí experimentů přínosnější a ulehčí to jejich další experimenty, třeba i s implementací vlastních bloků evolučních algoritmů.

1.2 Neuronové sítě

Umělé neuronové sítě jsou matematickou abstrakcí biologických neuronů a jejich chování v nervové soustavě. Umělé neurony jsou zjednodušeně vrcholy v grafu, propojeného hranami s váhami (podobně jako reálné neurony jsou propojeny synapsemi) Každý neuron počítá svůj potenciál jako vážený součet příchozích vzruchů přicházejících korespondujícími vstupními hranami. Nakonec je na potenciál neuronu aplikována nelineární aktivační funkce dále transformující potenciál na výstupní hodnotu neuronu.

Neuron Nejmenší jednotkou neuronových sítí je jeden neuron. Pro neuron s n vstupy, jejichž hodnoty označíme x_1,...,x_n a váhy korespondujících hran označíme

w_1,...,w_n, potom výstupní hodnotu tohoto neuronu, označenou O, můžeme spočítat jako,

$$O = f(\sum_{i=1}^{n} x_i w_i + b) \tag{1.1}$$

kde f je nelineární aktivační funkce na neuronu a b je *bias* daného neuronu, což je hodnota, která se přičítá k váženému součtu, sloužící jako offset výsledku.

Aktivační funkce Aktivační funkce slouží k transformaci potenciálu neuronu na výstupní hodnotu. Nejčastěji se jedná o nelineární transformaci pomocí nelineární funkce. Dnes nejpoužívanějšími aktivačními funkcemi jsou *logistická sigmoida* (vzorec 1.2, graf 1.1), *hyperbolický tangens* (vzorec 1.3, graf 1.2) nebo *ReLU* (vzorec 1.4, graf 1.3). Pokud potenciál neuronu před použitím aktivační funkce f označíme ξ,

$$f(\xi) = \frac{1}{1 + e^{-\xi}} \tag{1.2}$$

$$f(\xi) = tanh(\xi) = \frac{2}{1 + e^{-2\xi}} - 1 \tag{1.3}$$

$$f(\xi) = \max(0, \xi) \tag{1.4}$$

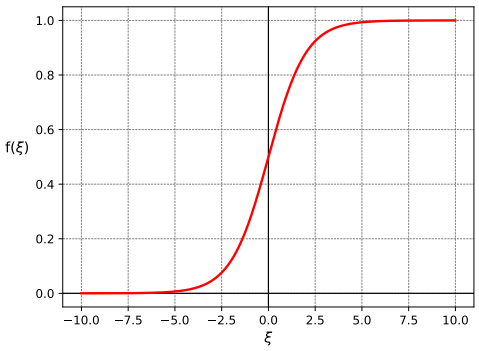

Obrázek 1.1: Funkce *sigmoid*

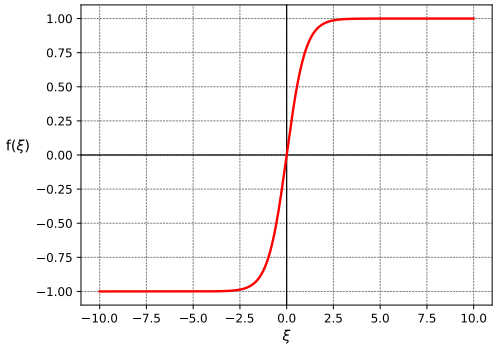

Obrázek 1.2: Funkce *tanh*

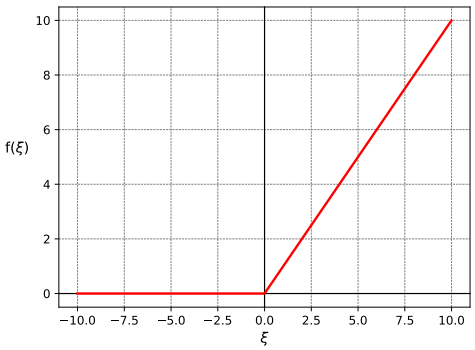

Obrázek 1.3: Funkce *ReLU*

Neuronová síť Architektura neuronové sítě je tvořena ze třech základních typů neuronů – vstupní (ze kterých pouze vycházejí spojení), výstupní (do kterých pouze přicházení spojení) a skryté (spojení přicházejí a jsou předávány dál). Neuronová síť pak jde popsat jako orientovaný graf. Pokud se jedná o graf bez orientovaných cyklů můžeme síť označit za *dopřednou neuronovou síť*. Pokud obsahuje nějaké orientované cykly, označujeme ji jako *rekurentní neuronovou síť*. Dále se budeme zaměřovat na *dopředné neuronové sítě*.

V těchto sítích vstup přechází po orientovaných hranách vrstvami neuronů, kde každý neuron z předchozí vrstvy je spojen hranou s každým vrcholem následující vrstvě. První vrstva se nazývá *vstupní vrstva*, tvořena ze *vstupních neuronů*, a slouží pro vstup parametrů (vstupů) do sítě. Poslední vrstva se nazývá *výstupní vrstva*. Je tvořena z *výstupních neuronů* a můžeme na ní sledovat výstupy neuronové sítě. Každá neuronová síť musí nutně mít alespoň jeden vstupní a alespoň jeden výstupní neuron. Libovolná další vrstva mezi *vstupní* a *výstupní vrstvou* se nazývá *skrytá vrstva*. Těchto vrstev může být v síti teoreticky neomezené množství.

Následující rovnice předvedou jeden dopředný průchod neuronovou sítí přenášející vstupní vektor hodnot na výstupní vektor. V tomto příkladu si představíme průchod dat jednoduchou sítí, skládající se ze vstupní vrstvy (potenciál vstupních neuronů značíme x_1,...,x_n), jedné skryté vrstvy neuronů (potenciály neuronů v této vrstvě označíme h_1,...,h_k, s korespondujícím vektorem *biasů* b_1,...,b_k) a výstupní vrstvy (potenciál neuronů výstupní vrstvy y_1,...,y_m opět s vektorem *biasů* b_1,...,b_m).

$$h_i = f(\sum_j^n x_j w_{j,i} + b_i), \quad i = 1,...,k \tag{1.5}$$

$$y_i = a(\sum_j^k h_j w_{j,i} + b_i), \quad i = 1,...,m \tag{1.6}$$

kde f je aktivační funkce neuronů skryté vrstvy a a je aktivační funkce neuronů výstupní vrstvy. Rovnice 1.5 představuje výpočet potenciálu neuronů ve skryté vrstvě naší neuronové sítě z příkladu a rovnice 1.6 představuje výpočet potenciálů výstupních neuronů této sítě.

Trénování neuronových sítí Trénování (nebo učení) neuronových sítí je často velmi složitý proces, při kterém se snažíme nastavit hodnoty vah jednotlivých spojů mezi neurony tak, abychom pro konkrétní vstup na *vstupní vrstvě*, dostali požadovaný výstup na *výstupní vrstvě*.

Toto je nejčastější požadavek pro neuronové sítě při tzv. *učení s učitelem* (*supervised learning*). Při tomto učení síť dostává dvojice vektorů (x, t), kde x je vektor vstupních hodnot a t je vektor požadovaných výstupů. Následně se x nastaví jako potenciál vstupních neuronů a síť spočítá výstupy na výstupních neuronech. Vektor výstupních neuronů (obvykle značený y) se porovná s požadovaným výstupem t. Na základě rozdílů (chyby) těchto hodnot se provede úprava vah jednotlivých spojů tak, aby se při opakovaném výpočtu sítě chyba zmenšila. Tohoto lze dosáhnout často používaným algoritmem zpětného šíření chyby (*backpropagation*), který počítá derivace chybové funkce, aby vždy prováděl úpravy vah spojů ve směru klesající chybové funkce.

Tento přístup ale přestává fungovat, pokud nedokážeme vytvořit vstupní trénovací dvojice *(vstup, požadovaný výstup)*, a tedy bychom nevěděli jakým směrem váhy spojů upravovat. Toto je překážka v mnoha praktických problémech, na které by se neuronové sítě hodilo použít. Možným řešením je nevyužívat učící metody založené na propagaci výsledné chyby sítě, ale použít nějakou hodnotící funkci, která ohodnotí kvalitu konfigurace dané sítě (např. po simulačním běhu). Toto nás vede na možnost využití evolučních algoritmů pro trénovaní neuronových sítí evolučním vývojem.

1.3 Neuroevoluce

Neuroevoluce Lehman a Miikkulainen (2013) je technika pro evoluční vývoj umělých neuronových sítí pomocí principů evolučních algoritmů (popsáno v sekci 1.1). Vývoj pomocí neuroevoluce je obecnější než vývoj pomocí klasických trénovacích metod, jelikož vývoj, na rozdíl od trénovacích metod založených na principu *učení s učitelem*, může probíhat i na sítích proměnlivé architektury a nepotřebuje znát korektní výstupy pro daný vstup sítě. Pro trénovaní stačí, když jsme schopni nějakým způsobem ohodnotit kvalitu řešení, k jakému se s využitím dané konfigurace (architektura a váhy spojení) sítě dostaneme. Díky tomuto se neuroevoluce hodí pro vývoj neuronových sítí v případech, kdy nejsme schopni přesně určit správné výstupy sítě a pouze můžeme pozorovat kvalitu chování daného vyvíjeného systému.

Vývoj neuronových sítí Vývoj pomocí neuroevoluce probíhá stejně jako u jiných evolučních algoritmů. Neuronová síť je zakódovaná do genotypu jedinců, množina těchto jedinců potom tvoří populaci, procházející vývojem skrz opakované generace. V každé generaci je genotyp každého jedince dekódován a z těchto informací vytvořena neuronová síť podle dekódované architektury a vah spojení. Pro každého jedince je jeho dekódovaná síť následně otestována v testovacím prostředí, kde se ohodnotí kvalita jedince (fitness).

Jednoduchým typem kódování může být uložení hodnot vah všech hran v neuronové síti do jediného vektoru. Takový vektor se použije jako genotyp jedince. To umožňuje optimalizaci vah sítě s fixní architekturou. Tento typ kódování může být ale výpočetně velmi náročný, kvůli rychle narůstající délce genotypu s velikostí architektury (počet vrstev a počet neuronů v síti) neuronové sítě.

Pokročilé metody S těmito problémy se můžeme potýkat hned několika způsoby. Různé styly zakódování neuronových sítí do genotypu umožňují vývoj mnohem rozsáhlejších sítí, zachovávající udržitelně malou velikost genetické informace jedinců.

Některé metody Gomez a kol. (2008) navrhovaly postup, jakým můžeme omezit vývoj z celých neuronových sítí na pouze menší komponenty, které dále mohly být spojovány dohromady s ostatními jedinci v kooperativní evoluci. To umožnilo evoluční vývoj sítí rozsáhlejších architektur s menšími nároky na velikost genotypu.

Jiné metody se poté zaměřily na vývoj jak vah, tak topologie neuronové sítě. Navíc se ukázalo, že současný vývoj topologie často přináší lepší výsledky, než

vývoj pouze vah sítě. Vývoj v těchto metodách začíná s nejzákladnější strukturou sítě, která se podle nároků problému sama vyvíjí a rozšiřuje, dokud tyto změny přináší kvalitativní zlepšení. Často využívaným algoritmem využívající těchto metod je algoritmus NEAT (*NeuroEvolution of Augmenting Topologies*), který si představíme v následujícím oddílu.

1.3.1 NEAT

NEAT (*NeuroEvolution of Augmenting Topologies*) (Stanley a Miikkulainen, 2002) je neuroevoluční algoritmus vyvíjející najednou váhy synapsí i topologii neuronové sítě, který se díky své výkonnosti stal jedním z nejznámějších algoritmů používaných pro účely evolučního vývoje neuronových sítí. Autoři jeho efektivitu připisují třem základním principům, se kterými algoritmus pracuje:

1. značení genetických informací pomocí tzv. *historických značek*, umožňující smysluplné křížení genotypů napříč různými topologiemi,
2. ochrana nových genetických informací v populaci pomocí rozdělení do druhů,
3. postupný vývoj topologie sítí od nejjednodušších struktur ke složitějším

S těmito principy se NEAT ukázal jako algoritmus, který často nachází efektivní sítě rychleji než ostatní algoritmy a výkony překonal nejlepší neuroevoluční algoritmy pracující s neuronovými sítěmi s fixní topologií.

Algoritmus NEAT používá tzv. *přímé kódování*, tedy genotyp každého jedince přímo popisuje celou topologii sítě (všechny neurony a všechny hrany mezi neurony). Každý genotyp obsahuje seznam *genů synapsí* a seznam *genů neuronů*. Seznam genů neuronů popisuje vstupní, výstupní a skryté neurony sítě, které mohou být spojené hranami. Každý gen synapse obsahuje následující informace:

- vstupní neuron – neuron, do kterého synapse vchází,
- výstupní neuron – neuron, ze kterého synapse vychází,
- hodnotu váhy synapse,
- příznak, jestli je spojení v síti použito,
- *historická značka* – číslo, popisující kdy v historii byla daná hrana do sítě přidána; umožňuje nacházet odpovídající geny synapsí při křížení.

Algoritmus začíná s nejzákladnější strukturou, připomínající jednoduchý perceptron, pouze s předem daným počtem vstupních a výstupních neuronů a hranami mezi nimi. Tato jednoduchá topologie je rozšiřována pomocí následujících genetických operátorů.

Mutace Mutace v algoritmu NEAT má schopnost měnit jak spojení v síti, tak její strukturu. Mutace synapsí sítě zahrnují jednoduchou změnu váhy spojení nebo změnu příznaku použití daného spojení v síti. Struktura sítě může mutovat dvěma způsoby. První typ mutace přidává nový gen synapsí, spojující dva doposud nespojené neurony. Druhý typ mutace přidává nový neuron. Tato mutace probíhá tak, že na místo existující synapse se přidá nový neuron. Původní synapse se označí jako nepoužívaná a namísto toho se vytvoří dvě nové rozdělující tu původní. Váha spojení je v tomto procesu zachována. Při těchto operacích je vždy novým genům synapsí navýšeno jejich *inovační číslo* (používá globální čítač inovací, jehož číslo je s každým novým genem navýšeno). Růst sítí probíhá právě díky mutaci.

Křížení Křížení probíhá za pomoci *inovačních čísel*. Dva jedinci se nejdříve hranami zarovnají pomocí jejich *inovačních čísel*. Stejná čísla totiž v síti značí stejnou strukturu. Synapse, která se v obou jedincích schoduje se dědí náhodně z jednoho rodiče. Synapse, kterou má jen jeden z rodičů se dědí z toho lepšího z dvojce rodičů a pokud je v nějakém jedinci hrana neaktivní a v druhém aktivní, s určitou pravděpodobností se tento stav v novém jedinci změní. Algoritmus je tímto stylem schopný vytvářet velké množství různých topologií. Tyto nové topologie, přestože často důležité pro řešení zadaného problému, ale mají jen velmi malou šanci se v populaci menších topologií udržet, protože původní menší topologie jsou na začátku často optimálnější než větší topologie. Proto NEAT využívá systém, kterým chrání tyto nové topologie před vyhynutím z populace.

Ochrana nových druhů Nové topologie jsou chráněny rozřazením genotypů do odlišných druhů. Jednotlivé genotypy poté primárně soutěží s jedinci stejného druhu a nové druhy tak mají šanci se vyvinout a optimalizovat na jejich úroveň. NEAT pro výpočet odlišností jedinců opět využívá *inovační čísla*, pomocí kterých hledá společné hrany a vypočítá vzdálenost dvou genomů. Geny můžeme dělit do několika kategorií. Buď se shodují a pak jsou označené jako *matching genes*, nebo se neshodují. Poté v závislosti na tom, jestli se neshodné geny objevují v rozmezí hodnot *inovačních čísel* druhého z jedinců nebo mimo toto rozmezí, nazývají se tyto geny buď *disjoint*, nebo *excess*. Hodnota vzdálenosti dvou jedinců se poté počítá jednoduchou lineární kombinací genů různých typů mezi jedinci pomocí inovačních čísel jako

$$\delta = \frac{c_1 E}{N} + \frac{c_2 D}{N} + c_3 \cdot \overline{W} \tag{1.7}$$

kde N je celkový počet genů ve větším z jedinců, E je počet *excess* genů, D je počet *disjoint* genů, $\overline{W}$ je průměrný rozdíl vah shodujících se genů a koeficienty c_1, c_2 a c_3 umožňují nastavovat důležitost těchto tří faktorů (Stanley a Miikkulainen, 2002).

V každé generaci se pak vytváří seznam různých druhů a pokud se objeví genom, který nezapadá do žádného z druhů, je pro něj vytvořen jeho vlastní nový druh.

Fitness Rozdělení do druhů má vliv i na fitness jedinců. Kvalita každého jedince se při výpočtu fitness dělí počtem jedinců stejného druhu. To zároveň omezuje

druhy v ovládnutí celé generace a dál ochraňuje nové topologie.

Minimalizace dimenzionality jedinců Jak již bylo zmíněno, algoritmus NEAT inicializuje celou jedinců s minimální topologií, obsahující pouze potřebný počet vstupních a výstupních neuronů, které jsou navzájem plně propojené a žádné skryté neurony. Nové topologie vznikají díky genetickým operátorům a všechna zvětšení genotypů jsou tedy v evoluci opodstatněná. Díky tomuto NEAT samovolně vede k vývoji minimálních topologií. To umožňuje, že tento algoritmus je často výkonnější než ostatní, protože prohledává minimální potřebný prostor pro najití řešení, oproti neuroevolučním algoritmům používající fixní topologie neuronových sítí.

1.3.2 HyperNEAT

Algoritmus HyperNEAT (*Hypercube-based NEAT*) (Stanley a kol., 2009) (Eplex) je neuroevoluční algoritmus rozšiřující algoritmus NEAT. HyperNEAT slouží pro vývoj umělých neuronových sítí fixní topologie (typicky omezená tvarem hyperkrychle).

Na rozdíl od algoritmu NEAT, používá HyperNEAT nepřímou reprezentaci vah sítě. Tyto váhy jsou reprezentovány pomocí jiné neuronové sítě (*Compositional Pattern-Producing Network*, zkráceně *CPPN*), která jako vstup dostává pozice dvou neuronů v prostoru a vrací váhu jejich spojení (synapse). Tímto stylem může *CPPN* být využita pro reprezentaci sítě libovolné topologie.

Síť *CPPN* je poté v algoritmu HyperNEAT vyvíjena pomocí NEAT.

Díky této nepřímé reprezentaci vah má HyperNEAT schopnost efektivně vyvinout velmi rozsáhlé neuronové sítě s předem určenou strukturou (schopnost napodobit regularitu velkého množství spojů v lidském mozku).

Následuje naznačení průběhu HyperNEAT algoritmu:

1. Zvolit konfiguraci vyvíjené sítě (vstupní a výstupní neurony a rozložení skrytých neuronů),
2. Inicializovat NEAT algoritmus s *CPPN* sítěmi,
3. Běh NEAT algoritmu, dokud není nalezeno řešení:
   (a) Pomocí *CPPN* daného jedince vytvoř synapse pro původní síť,
   (b) Síť otestuj v testovacím prostředí pro výpočet kvality řešení,
   (c) S fitness hodnotami pokračuj ve vývoji genotypů popisujících *CPPN* sítě.

1.4 Simulované prostředí

++ Rozlišit simulátory

Jelikož chceme vyvíjet řízení robotů založené na interakcích s prostředím, je pro tuto práci důležité vybrat vhodný simulátor prostředí, založený na skutečných fyzikálních zákonech. Přáli bychom si mít možnost jednoduše konfigurovat

co nejvíce vlastností prostředí a zároveň mít co nejjednodušší přístup k morfologii simulovaných robotů. Zároveň chceme, abychom měli možnost do morfologie robotů nějakým způsobem zasahovat i v průběhu evolučního vývoje a aktivně ji za běhu měnit. Jelikož plánujeme v různých prostředích provádět experimenty s různými typy robotů, používajícími různé styly pohybu (typy motorů, kloubů, tvarů končetin, atd.), je potřebné, aby fyzikální simulátor (*fyzikální řešič=solver*) byl schopný simulovat i složitější typy robotů. Takovými mohou být právě třeba kráčející roboti, neboli roboti používající k pohybu končetiny připomínající nohy, na rozdíl od jednodušších typů robotů, kteří se mohou pohybovat pomocí kol, jejichž simulace bývá mnohdy jednodušší.

Stejně tak, jak potřebujeme umožnit simulaci složitějších robotů, protože nebudeme mít možnost vlastnoručně kontrolovat každý parametr, který bude při vývoji robotům přiřazen, potřebujeme zajistit, aby fyzikální simulátor zvládal velké rozsahy parametrů a simulace zůstala s těmito parametry stabilní. Zároveň chceme, aby simulátor v prostředí byl deterministický, což umožní, že předváděné experimenty můžeme dle potřeby opakovat a výsledky tak náležitě prezentovat.

Evoluční algoritmy jsou velmi lehce paralelizovatelné a tedy pro urychlení procesu vývoje a experimentů bude pro nás výhodné, pokud by simulace zvládala paralelní běh na více vláknech (více simulací, každá na vlastním vlákně). V poslední řadě pro lehčí integraci do vlastního modulu bude užitečné, aby modul spravující zvolený simulátor byl open-source, což nám dá volnost v případě, že si budeme chtít chování systémů v prostředí nějak vlastnoručně upravit.

1.4.1 Simulátory prostředí

Při hledání simulátorů prostředí, které by vyhovovali našim požadavkům a umožňovali kontrolu a ovládání prostředí prostřednictvím zvoleného jazyka Python, jsme narazili na několik možností. Omezený výčet těchto simulátorů zde popíšeme – Gazebo (v oddílu 1.4.1.1), Webots (v oddílu 1.4.1.2) a CoppeliaSim (v oddílu 1.4.1.3). Poté se pak v sekci 1.4.2 podíváme na několik nejpoužívanějších fyzikálních simulátorů.

1.4.1.1 Gazebo

Gazebo (OpenRobotics) je sada open-source víceplatformních knihoven pro vývoj, výzkum a aplikaci robotů, která vznikla v roce 2002. Umožňuje kompletní kontrolu nad simulací dynamického 3D prostředí s více agenty a generování dat ze simulovaných senzorů. Fyzikálně korektní interakce v prostředí pak od začátku projektu zajišťuje známý fyzikální simulátor ODE (viz sekce 1.4.2.1), nad kterým Gazebo tvoří abstraktní vrstvu, umožňující snazší tvorbu simulovaných objektů různých druhů. V dnešní době je stále výchozím fyzikálním simulátorem ODE, nicméně uživatel již může vybrat celkem ze čtyř různých fyzikálních simulátorů – Bullet (sekce 1.4.2.2), Simbody, Dart (sekce 1.4.2.3) a ODE. Uživatel s knihovnou pracuje prostřednictvím grafického rozhraní založené na knihovně Open Scene Graph používající OpenGL, nebo prostřednictvím příkazové řádky. Prostředí a roboti mohou být tvořené buď z grafického rozhraní prostředí, nebo v textovém formátu XML. Limitací Gazebo je pak chybějící možnost rozdělit simulace mezi vícero vláken kvůli vnitřní architektuře spojené s fyzikální simulací (Koenig a Howard, 2004).

1.4.1.2 Webots

Webots (Webots) je open-source víceplatformní, robustní a deterministický robotický simulátor vyvíjený od roku 1998, umožňující programování a testování virtuálních robotů mnoha různých typů a jednoduchou následnou aplikaci softwaru na reálné roboty. Simulátor je možné použít pro simulaci prostředí s vícero agenty najednou s možnostmi lokální i globální komunikace mezi agenty. Výpočty fyzikálních interakcí zajišťuje fyzikální simulátor ODE. Pro vývoj robotů a prostředí je možné využít řady programovacích jazyků a to C, C++, Python, Java, MATLAB nebo ROS (*Robot Operating System*). Prostředí umožňuje práci v grafickém rozhraní a vizualizaci simulací pomocí OpenGL. Knihovna dále nabízí využití připravených modelů robotů, vlastní editor robotů a map a možnosti vložení vlastních robotů z 3D modelovacích softwarů v CAD formátu (Michel, 2004).

1.4.1.3 CoppeliaSim

CoppeliaSim (Rohmer a kol., 2013) (CoppeliaRobotics) (původně známý pod jménem *V-REP = Virtual Robot Experimentation Platform*) je víceplatformní simulační modul pro vývoj, testování a jednoduchou aplikaci softwaru pro roboty. Dovoluje vývoj ovladačů pomocí 7 různých programovacích jazyků a ulehčuje jejich aplikace v simulovaných a skutečných robotech. Simulaci ovladačů je možno jednoduše rozdistribuovat mezi vícero vláken dokonce vícero strojů, což urychluje vývoj a snižuje nároky na procesor v době simulace. Navíc je možné vyvíjený ovladač nechat v době simulací běžet na vlastním na dálku připojeném robotovi, co dále ulehčuje přenos finální verze ovladačů od vývoje do skutečného světa. Prostředí umožňuje práci s širokou řadou typů objektů, druhů kloubů, senzorů a dalších objektů obvykle používaných při vývojích robotických ovladačů. Obsahuje lehce použitelný editor prostředí a robotů samotných s řadou předem vytvořených modelů, které může uživatel hned využít. Modely zároveň mohou být přidány v řadě různých formátů (XML, URDF, SDF). Prostředí podporuje pět různých fyzikálních simulátorů (Bullet, ODE, MuJoCo (v sekci 1.4.2.4), Vortex (v sekci 1.4.2.5) a Newton), mezi kterými si uživatel může vybrat dle potřeb přesnosti (reálnosti), rychlosti a dalších možností jednotlivých fyzikálních simulátorů (Nogueira, 2014).

1.4.2 Fyzikální simulátory

V této podkapitole se podíváme na základní popis a možné výhody a nevýhody jednotlivých fyzikálních simulátorů, na které jsme narazili při hledání simulátorů prostředí.

1.4.2.1 ODE

ODE (*Open Dynamics Engine*) (Smith) je víceplatformní open-source fyzikální simulátor, jehož vývoj začal v roce 2001. Je vhodný pro simulaci pevných těles s různými druhy kloubů a pro detekci kolizí. Byl navržen pro využití v interaktivních nebo real-time simulacích, upřednostňujících rychlost a stabilitu nad fyzikální přesností (Smith a kol., 2007). Vyžaduje používat menší simulační kroky

kvůli stabilitě. Hodí se pro simulaci vozidel, kráčejících robotů a virtuálních prostředí. Má široké využití v počítačových hrách a 3D simulačních nástrojích jako jsou CoppeliaSim (v sekci 1.4.1.3), Gazebo (v sekci 1.4.1.1), Webots (v sekci 1.4.1.2) a dalších.

1.4.2.2 Bullet

Bullet je open-source fyzikální knihovna, podporující detekci kolizí a simulaci pevných a měkkých těles. Bullet je používán jako fyzikální simulátor pro hry, vizuální efekty a robotiku (Coumans). Byl použit jako hlavní fyzikální simulátor pro simulaci NASA *Tensegrity* robotů (s vlastními úpravami pro simulaci měkkých těles, kvůli nerealistickým metodám řešení simulace provazů) (Izadi a Bezuijen, 2018).

1.4.2.3 Dart

Dart (*Dynamic Animation and Robotics Toolkit*) je víceplatformní open-source knihovna pro simulace a animace robotů. Od předchozích se odlišuje stabilitou a přesností, díky zobecněné reprezentaci souřadnic pevných těles v simulaci. Na rozdíl od ostatních fyzikálních simulátorů, aby dal vývojáři plnou kontrolu nad simulací, umožňuje Dart plný přístup k interním hodnotám simulace. Zároveň se díky línému vyhodnocování hodí pro vývoj real-time ovladačů pro roboty (Lee a kol., 2018).

1.4.2.4 MuJoCo

MuJoCo (*Multi-Joint Dynamics with Contact*) (DeepMind, 2021) je open-source fyzikální simulátor pro vývoj v oblasti robotiky, biomechaniky a dalších. Často je využíváno pro testování a porovnávání různých metod navrhování robotických systémů jako jsou třeba evoluční algoritmy nebo metody zpětnovazebného učení (Salimans a kol., 2017). V simulacích je pro roboty možné nakonfigurovat využití mnoha druhů aktuátorů, včetně těch simulujících práci svalů a k dispozici je i velké množství kloubů. Simulátor zároveň umožňuje velký nárůst v rychlosti běhu simulace za pomoci plné podpory paralelizace na všech dostupných vláknech a stabilitě simulace i při velmi velkých simulačních krocích (Todorov a kol., 2012). Zároveň nabízí jednoduchý styl, jakým si může uživatel konfigurovat všechny detaily simulace a samotných simulovaných robotů pomocí jednoduchých XML konfiguračních souborů (XML formát modelů *MJCF*). V komplexním rozboru řady četně používaných fyzikálních simulátorů byl simulátor MuJoCo hodnocen jako jeden z nejlepších co se týče stability, přesnosti a rychlosti simulací. Další výhodou zlepšující přesnost tohoto simulátoru je, že MuJoCo pro simulaci používá kloubní souřadnicový systém, který předchází narušení fyzikálních pravidel a tedy nepřesností v kloubech (Erez a kol., 2015).

1.4.2.5 Vortex

Vortex je uzavřený, komerční fyzikální simulátor určený pro tvorbu reálnému světu odpovídajících simulací. Obsahuje mnoho parametrů, umožňující nastavení reálných fyzikálních parametrů dle potřeb, většinou industriálních a výzkumných aplikací (CoppeliaRobotics) (Yoon a kol., 2023).

1.4.2.6 Porovnání simulátorů

V dnešní době se nám nabízí velké množství potencionálních kandidátů, vhodných k využití pro naši aplikaci. Prakticky každý z open-source simulátorů, které jsme našli a předvedli, by bylo možné použít pro simulaci robotů složitosti, jakou máme předběžně v plánu. Hlavním z rozhodujících faktorů pro tento projekt bude jak jednoduše půjde prostředí používat pro vývoj pomocí genetických algoritmů. Chceme tedy nějaký jednoduchý přístup k simulaci a ovládání robotů, rychlost a přesnost simulace.

Opět většina ze simulátorů prostředí toto nabízí. Osobně se nám ale nejvíce zalíbilo MuJoCo. Díky nedávnému otevření fyzikálního simulátoru MuJoCo a změně prostředí (nejprve do **OpenAI Gym** a nyní do **Farama Foundation Gymnasium**) jsme dostali možnost využít jednoduché Python API pro ovládání robotů a zároveň konfiguraci celé simulace.

Tato abstrakce od vlastní simulace je pro tuto práci velmi přínosná, protože se především chceme zajímat o vývoj řízení robotů pomocí evolučních algoritmů. Řešit zároveň složité ovladače robotů, které by se mohly lišit pro různé typy robotů, by mohlo bezdůvodně komplikovat celý proces spojení evolučních algoritmů s řízením robotů. Takové věci by pak mohly být problematické pro možného uživatele, který by si chtěl sám evoluční algoritmy upravovat.

MuJoCo se zároveň ukazuje jako jeden z nejlepších volně dostupných fyzikálních simulátorů dnes. Z výsledků článku testujících různé vlastnosti známých fyzikálních simulátorů Erez a kol. (2015) vychází, že MuJoCo má navrch jak v rychlosti, tak ve kvalitě simulací. Zároveň interně využívá kloubní souřadnicový systém, který je přesnější, protože zabraňuje nepřesnostem v kloubech. To se hodí o to více, když v této práci chceme vyvíjet hlavně kráčející roboty, u kterých můžeme mít i větší počty kloubů.

Simulátor MuJoCo a roboti, které můžeme používat, je zároveň možné jednoduše konfigurovat pomocí vlastního XML formátu a spojení s Python API navíc umožní tyto konfigurace provádět jak často bude potřeba.

2. Specifikace

Vývoj pomocí evolučních algoritmů je možné nejlépe představit pomocí experimentů, na kterých může uživatel sám pozorovat změny, kterými postupný iterativní evoluční vývoj nachází možná řešení na zadaný problém. Je ale složité vytvořit takový systém, ve kterém by uživatel mohl snadno ovládat interní části evolučních algoritmů a tak vytvářet vlastní různorodé experimenty. A právě tyto experimenty mohou být zásadní pro pochopení specifických zákoutí aplikace evolučních algoritmů.

Proto cílem tohoto projekt je navržení knihovny, která by uživatelům, přicházejících z různých odvětví, umožnila bližší pochopení a seznámení se s evolučními algoritmy pomocí vlastních interaktivních experimentů při vývoji robotů v simulovaném prostředí.

I jednoduché problémy, které od robotů můžeme požadovat vyřešit (např. ujití největší možné vzdálenosti za daný čas), poskytují roboti různé komplexity (různé morfologie, počtu kloubů, atd.) dobrou představu v nárůstu obtížnosti daného problému. Tímto zároveň experimenty s různými roboty vynucují využití různých pokročilejších metod pro dosažení chtěných cílů daného experimentu.

V následující sekci 2.1 zabývající se funkčními požadavky si představíme jednotlivé části, které od takového systému budeme požadovat.

2.1 Funkční požadavky

Tento projekt cílí vytvořit systém, umožňující uživatelům vytvářet vlastní experimenty s evolučním vývojem robotů v simulovaném fyzikálním prostředí. Uživatel by měl být schopný před spuštěním experimentu podrobně pochopit a upravit co nejvíce částí evolučního vývoje, který bude v době experimentu probíhat. Uživatel musí být v době běhu experimentu schopný sledovat průběžné výsledky z jednotlivých generací a vizualizovat dosavadní výsledky v simulovaném prostředí. Po dokončení experimentu musí být možnosti uložit výsledky ve formě dále zpracovatelné pro umožnění statistického rozbor většího množství experimentů s možností vizualizace dat nejlepších jedinců finálních generací.

Systém bude z hlavní části vytvořený v programovacím jazyce Python, vytvářející uživateli přístupnější kód a umožňující rychlejší experimentování a prototypování nápadů. Python je vhodný, jelikož se pro tento systém nesnažíme o maximální efektivitu nebo rychlost experimentů, ale o čitelnost celého systému a schopnost vytvářet s naší knihovnou vlastní experimenty.

V následujících odstavcích si způsoby, jakými bude možný uživatel mít schopnost přistupovat k našemu systému pro tvorbu experimentů. Každý způsob přístupu k systému má své vlastní požadavky, které s sebou přináší.

Python knihovna Systém pro tvorbu experimentů vývoje robotů v simulovaném prostředí bude tvořit otevřenou Python knihovnu, kterou možný uživatel bude schopný připojit ke svému projektu a pomocí naší knihovny jednoduše vytvářet experimenty s požadovanou volností konfigurace jednotlivých parametrů evolučního vývoje.

V případě, že uživatel nebude knihovnu připojovat ke svému vlastnímu projektu, bude systém schopen fungovat samostatně. Zároveň bude mít knihovna dostatečnou dokumentaci na to, aby takový uživatel byl schopen provádět pokročilou konfiguraci experimentů přímo v kódu knihovny, a aby tyto experimenty bylo možné provádět z kódu, bez omezení výstupů systému nebo vizualizace řešení.

Grafické rozhraní Pro uživatele, kteří k systému chtějí jednoduchý přístup zprostředkovaný interaktivním grafickým rozhraním, musí systém umožňovat vytvářet a konfigurovat experimenty dostatečné složitosti z prostředí tohoto grafického rozhraní. Uživatel tímto způsobem bude dále schopný pozorovat průběžné výsledky evolučního vývoje a vizualizovat průběžná nejlepší řešení, které evoluční vývoj najde.

Rozšířitelnost Systém zároveň vytvoří rozšířitelnou platformu, která sama bude jednoduše konfigurovatelná a rozšířitelná pro pokročilejšího uživatelem. Představí a vysvětlí technologie využité při vývoji této knihovny a zanechá kód v přístupném a jednoduše rozšířitelném stavu.

3. Implementace

V předchozí kapitole jsme prošli funkční požadavky, očekávané od vyvíjeného souboru programů. Následuje rozbor jednotlivých modulů, které vznikly při vlastní implementaci. Zároveň zde projdeme možné alternativy, které se pro vývoj nabízejí a probereme důvody stojící za zvolením jednotlivých z možností.

Nejprve vysvětlíme volbu programovacího jazyka, ve kterém je celá knihovna vytvořena. Poté projdeme systémy umožňující vývoj ve fyzikálním prostředí a ovládání uživatelem definovaných robotů. Zde představíme i možnosti tvorby vlastních robotů. Dále ukážeme možné varianty modulů umožňující vývoj řízení robotů pomocí genetických algoritmů a popíšeme vlastní implementaci. Následně projdeme všechny části implementace spojující tyto moduly do přístupné rozšiřitelné knihovny. V poslední části představíme implementaci grafického rozhraní, které slouží uživateli, který chce používat knihovnu a provádět experimenty, bez nutnosti využití příkazové řádky.

3.1 Programovací jazyk

Jako programovací jazyk, ve kterém tento projekt bude psán, jsme zvolili **Python**. Cílem projektu je vytvořit platformu, kterou bude uživatel moci použít k vývoji robotů pomocí evolučních algoritmů. Pokud uživatel bude mít potřebu jakkoli připravený proces vývoje měnit, Python lehce umožní nahlédnout do zdrojových kódů vypracované knihovny a provést úpravy dle vlastních potřeb. Zároveň to umožňuje rozšiřování knihovny o nové metody, které bude chtít uživatel zkusit zařadit do již funkčního procesu. Jednoduchá čitelnost Pythonu spojená s rychlostí, jakou mohou být prováděny iterace změn bez potřeby zdlouhavého překladu celé knihovny, se zdají býti dostatečně dobré vlastnosti pro volbu programovacího jazyka pro tento projekt.

3.2 Simulované fyzikální prostředí

Po zhodnocení vypsaných a dalších možností jsme vybrali pro využití v tomto projektu fyzikální simulátor MuJoCo. Na rozdíl od ostatních se zdá býti přístupnější do začátku a zároveň dostatečně robustní a konfigurovatelný tak, aby splnil veškeré požadavky, které od fyzikálního simulátoru máme.

MuJoCo 1.50 je fyzikální simulátor zpřístupněný skrz volně dostupné aplikační rozhraní společnosti **OpenAI** v rámci jejich sady různých prostředí **Gym** (textové hry, jednoduché 2D i plně fyzikálně simulované 3D prostředí, Atari hry aj.) pro vývoj metod zpětnovazebného učení na různých problémech. Toto rozhraní umožňuje uživatelům jednoduchý přístup k datům z poskytnutých prostředí a ovládání prostředím definovaných agentů, pomocí standardizovaných vstupů i výstupů napříč všemi prostředími. Tímto způsobem můžeme velmi lehce ovládat i roboty v prostředích simulátoru MuJoCo. Navíc otevřená vlastnost tohoto aplikačního rozhraní umožňuje úpravu částí procesu tak, aby se lépe hodil při řešení námi zvolených problémů. Přestože je **Gym** převážně používána pro vývoj metod zpětnovazebného učení agentů, nic nám nebrání a je velmi jednoduché namísto

toho využít vlastního agenta, který je vyvíjen pomocí evolučních algoritmů.

3.2.1 Roboti

3.3 Genetické algoritmy

Po porovnání různých možností modulů pro tvorbu a použití evolučních algoritmů v naší knihovně, jsme se rozhodli pro vlastní implementaci jednotlivých částí evolučních algoritmů (genetických operátorů) a jejich propojení mezi sebou. Důvodem je hlavně jednodušší zapojení do zbytku knihovny a snížení nároků na znalosti mnohdy složitých výše popsaných externích knihoven pro uživatele, který by případně mohl chtít si do naší knihovny dopsat vlastní kus evolučního algoritmu. Tímto způsobem, pokud bude chtít něco takového udělat, dojde-li k dodržení zdrojovým kódem stanovených pravidel, vlastní kus kódu (metoda popisující genetický operátor) bude možné hned bez problému využít při dalším vývoji robotů.

3.4 Implementace knihovny

3.5 Grafické rozhraní

4. Experimenty a výsledky

V této kapitole se podíváme na tři typy experimentů, které s naším systémem můžeme provádět. Knihovna implementuje několik různých přístupů jak roboty řídit a jak je vyvíjet pomocí evolučních algoritmů. Následující experimenty předvedou vzorek z těchto přístupů.

Cílem všech následujících experimentů je pomocí evolučních algoritmů vyvinout zvoleného robota tak, aby byl schopný stabilního pohybu v simulovaném prostředí v předem určeném směru. Kvalita jedinců je pak jednoduše vypočtena dle následující rovnice:

$$fitness = x - 0.5 \cdot |y| \tag{4.1}$$

Každý jedinec začíná svůj simulační běh v prostředí v počátku na souřadnicích $(x,y) = (0,0)$, tedy v rovnici jsou x a y vzdálenosti od počátku, které jedinec v simulovaném prostředí urazil (buď do vypršení limitovaného času na simulaci, nebo do dosažení podmínky předčasně ukončující simulační běh – např. pád robota).

V prvním experimentu v sekci 4.1 se podíváme na ověření, zda pro řízení jednoduchých robotů nám stačí základní evoluční algoritmy a pro složitější roboty (s větším množstvím stupňů volnost) potřebujeme pokročilé přístupy. V následujících dvou experimentech v sekci 4.2 popíšeme experimenty předvádějící možnost evolučního vývoje jak řízení tak morfologie robotů.

4.1 Vývoj řízení robotů

V této sekci se zaměříme na vývoj řízení robotů. Vývoj řízení je ovlivněn hlavně zvoleným řídícím agentem, který popisuje zvolený evoluční algoritmus. Tento agent z genetických informací kóduje vstupy pro motory (nastavení kloubů) robota. Určití agenti mohou využívat přímou reprezentaci vstupů pro motory, kde sama genetická informace reprezentuje nastavení motorů. Jiní využívají nepřímou reprezentaci, kde genetické informace slouží jako parametry pro generování aktuálního nastavení motorů.

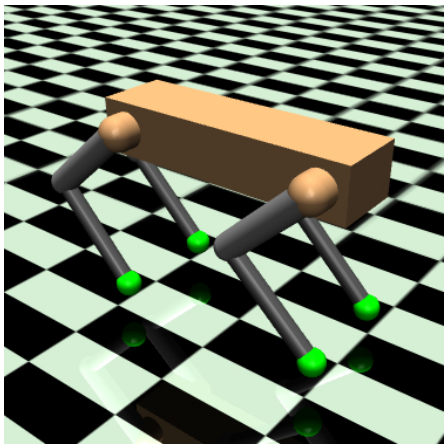

Obrázek 4.1: Robot *SpotLike*

První pokus se bude snažit vyvinout řízení pro pokročilého robota v projektu označovaném jako *SpotLike* (blíže popsaný v implementaci v sekci **??**). Jedná se o robota kráčejícího na čtyřech nohách, kde každá noha má 3 stupně volnost (tedy 12 celkem pro celého robota). Můžeme ho tedy řadit mezi roboty, u kterých již bude obtížnější vyvinout stabilní pohyb v určeném směru.

Kráčení, kterého bychom u robotů chtěli dosáhnout, si můžeme představit jako poměrně jednoduchý periodický pohyb. Proto se pro vývoj řízení pokusíme využít agenty, kteří interně podle parametrů generují periodické hodnoty pro motory robotů.

Nejdříve se pokusíme řízení robota vyvinout pomocí evolučního algoritmu, který kóduje nastavení motorů pomocí základních periodických funkcí (agent popisující tento algoritmus popsán v implementaci v sekci **??**). Každý motor robota má v tomto případě přiřazenou vlastní periodickou funkci a genotyp jedinců specifikuje parametry těchto periodických funkcí (4 parametry pro každý kloub – amplituda, frekvence, x a y posun).

Evoluční algoritmus poběží **200 generací** se **100** náhodně inicializovanými jedinci. Pro vyhodnocení bude celý běh evolučního algoritmu bude **pětkrát opakován** vždy s novou náhodně vygenerovanou první populací.

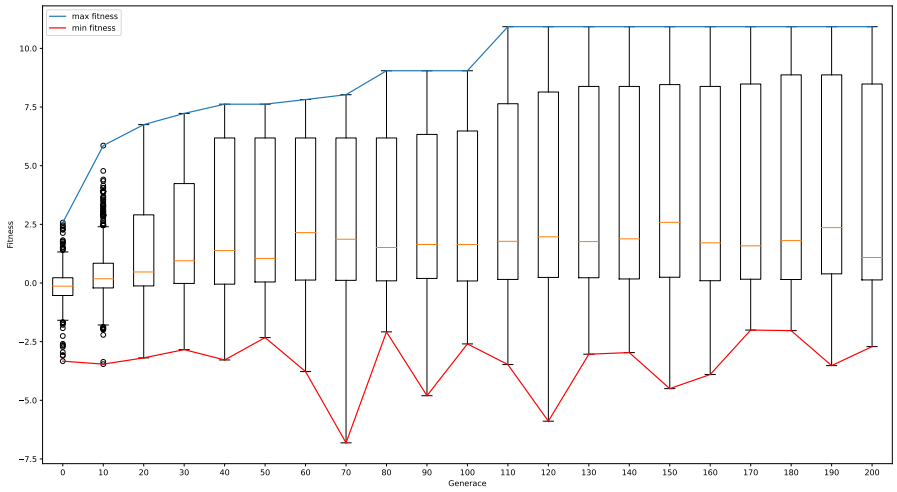

Obrázek 4.2: Průběh fitness populace v experimentu se základním agentem

Graf na obrázku 4.2 vizualizuje průběh vývoje fitness hodnot za běhu výše popsaného evolučního algoritmu. Data jsou vytvořena kombinací záznamů o fitness hodnotách v dané generaci ze všech pěti nezávislých běhů.

Z grafu se ukazuje, že tento přístup vývoje řízení dosáhl maximální hodnotu fitness okolo 10 a absolutní většina populace není schopna většího posunu.

Pro porovnání volíme pokročilého agenta, kódujícího nastavení motorů pomocí omezených Fourierových řad (agent popsán v sekci **??**). Tento agent je na úkor malého zvětšení genotypu, oproti předchozímu agentovi schopný generovat mnohem komplexnější periodické funkce popsané skládáním několika funkcí sinus.

Stejně jako v předchozím běhu, algoritmus poběží 200 generací se 100 jedinci a bude opět pětkrát zopakován.

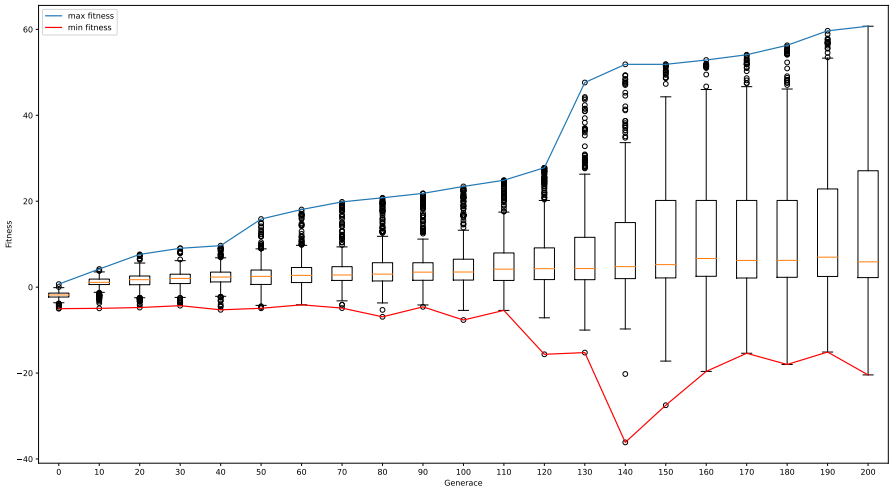

Obrázek 4.3: Průběh fitness populace v experimentu s pokročilým agentem

Graf 4.3 průběhu vývoje fitness hodnot z experimentu s pokročilým agentem ukazuje, že tento agent již je schopný vyvinout stabilní pohyb i pro zadaného komplexního robota. Maximální fitness hodnota, které při vývoji agent dosáhl se pohybovala okolo 60. Zároveň poměrně velká část populace byla schopná dosáhnout výsledků, přesahující nejlepší výsledky jednoduššího agenta. Průběh vývoje dále naznačuje, že pokud bychom navýšili počet generací, tak by byla možnost pohyb dále optimalizovat a dosáhnout tak ještě vyšší fitness.

Z experimentu, vedle hodnot pro zpětné statistické zpracování dat, dostaneme i nejlepšího jedince, který byl otestován v poslední generaci běhu evolučního algoritmu. Jelikož naše simulované fyzikální prostředí je deterministické, máme možnost jedince nahrát zpět do simulace a vizualizovat tak nejlepší řešení daného evolučního algoritmu.

Ruční kontrolou těchto výsledků jsme dále zjistili, že pouze část (dva z pěti běhů) dosáhly takového pohybu, který bychom od robota této morfologie očekávali. Pohybovali se tedy až na menší odchylku rovně, způsobem připomínající chůzi skutečných čtyřnohých zvířat. Zbylé běhy vyvinuly pohyb, který sice je schopný stabilní, ale ne zcela estetické chůze. Roboti se v těchto případech posouvali bokem vpřed, využívající většího rozsahu v rotaci (*kyčelních*) kloubů pro stabilizaci.

Osobně si myslím, že vývoj estetického pohybu pro tohoto robota je možný jen s malou úpravou hodnotící, která by například penalizovala rotaci těla od požadovaného směru pohybu. Myslím si, že chůze stranou je kvůli rozsahu (*kyčelních*) kloubů hlavně v ose délky těla robota, mnohem snazší na dosažení, tvořící zde silné lokální optimum. Agenti totiž velmi rychle konvergují ke způsobům chůze, které jsou stabilní a chůze stranou je oproti vratké chůzi rovně mnohem stabilnější. Úprava hodnotící funkce by měla být schopna toto lokální optimum penalizovat.

4.2 Vývoj řízení a morfologie robotů

4.2.1 Oddělený vývoj řízení a morfologie

4.2.2 Simultánní vývoj řízení a morfologie

4.3 Diskuze výsledků

Závěr

Seznam použité literatury

CoppeliaRobotics. https://www.coppeliarobotics.com. URL `https://www.coppeliarobotics.com`. Robot simulation software.

Coumans, E. Bullet real-time physics simulation. URL `https://pybullet.org/wordpress/`. Accessed: March 19, 2023.

DEAP, P. Deap documentation. URL `https://deap.readthedocs.io/`. Accessed: March 19, 2023.

DeepMind (2021). Mujoco. URL `https://mujoco.org/`. Accessed: March 26, 2023.

Eplex. URL `http://eplex.cs.ucf.edu/hyperNEATpage/`. Accessed: April 10, 2023.

Erez, T., Tassa, Y. a Todorov, E. (2015). Simulation tools for model-based robotics: Comparison of bullet, havok, mujoco, ode and physx. In *2015 IEEE international conference on robotics and automation (ICRA)*, pages 4397–4404. IEEE.

Fortin, F.-A., De Rainville, F.-M., Gardner, M.-A. G., Parizeau, M. a Gagné, C. (2012). Deap: Evolutionary algorithms made easy. *The Journal of Machine Learning Research*, **13**(1), 2171–2175.

Garrett, A. (2012). Inspyred: Bio-inspired algorithms in python. URL `https://pythonhosted.org/inspyred/`. Accessed: March 26, 2023.

Gomez, F., Schmidhuber, J., Miikkulainen, R. a Mitchell, M. (2008). Accelerated neural evolution through cooperatively coevolved synapses. *Journal of Machine Learning Research*, **9**(5).

Izadi, E. a Bezuijen, A. (2018). Simulating direct shear tests with the bullet physics library: A validation study. *PLOS one*, **13**(4), e0195073.

Koenig, N. a Howard, A. (2004). Design and use paradigms for gazebo, an open-source multi-robot simulator. In *2004 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)(IEEE Cat. No. 04CH37566)*, volume 3, pages 2149–2154. IEEE.

Lee, J., X. Grey, M., Ha, S., Kunz, T., Jain, S., Ye, Y., S. Srinivasa, S., Stilman, M. a Karen Liu, C. (2018). Dart: Dynamic animation and robotics toolkit. *The Journal of Open Source Software*, **3**(22), 500.

Lehman, J. a Miikkulainen, R. (2013). Neuroevolution. *Scholarpedia*, **8**(6), 30977. doi: 10.4249/scholarpedia.30977. revision #137053.

Michel, O. (2004). Cyberbotics ltd. webots™: professional mobile robot simulation. *International Journal of Advanced Robotic Systems*, **1**(1), 5.

Nogueira, L. (2014). Comparative analysis between gazebo and v-rep robotic simulators. *Seminario Interno de Cognicao Artificial-SICA*, **2014**(5), 2.

OpenRobotics. URL https://gazebosim.org/. Accessed: March 26, 2023.

Rohmer, E., Singh, S. P. N. a Freese, M. (2013). Coppeliasim (formerly v-rep): a versatile and scalable robot simulation framework. In *Proc. of The International Conference on Intelligent Robots and Systems (IROS)*. www.coppeliarobotics.com.

Salimans, T., Ho, J., Chen, X., Sidor, S. a Sutskever, I. (2017). Evolution strategies as a scalable alternative to reinforcement learning. *arXiv preprint arXiv:1703.03864*.

Smith, R. URL http://ode.org/. Accessed: March 26, 2023.

Smith, R. a kol. (2007). Open dynamics engine.

Stanley, K. O. a Miikkulainen, R. (2002). Evolving neural networks through augmenting topologies. *Evolutionary computation*, **10**(2), 99–127.

Stanley, K. O., D'Ambrosio, D. B. a Gauci, J. (2009). A hypercube-based encoding for evolving large-scale neural networks. *Artificial life*, **15**(2), 185–212.

Todorov, E., Erez, T. a Tassa, Y. (2012). Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ international conference on intelligent robots and systems*, pages 5026–5033. IEEE.

Tonda, A. (2020). Inspyred: Bio-inspired algorithms in python. *Genetic Programming and Evolvable Machines*, **21**(1-2), 269–272.

Webots. http://www.cyberbotics.com. URL http://www.cyberbotics.com. Open-source Mobile Robot Simulation Software.

Yoon, J., Son, B. a Lee, D. (2023). Comparative study of physics engines for robot simulation with mechanical interaction. *Applied Sciences*, **13**(2), 680.

A. Přílohy

A.1 První příloha